Setul de date AUTOVIT

Vizualizarea datelor

Am facut mai multe grafice pentru acest set de date:

- Distributia Variabilei Tinta (pretul)
- Analiza datelor lipsa
- Matricea de corelatie intre atribute numerice
- Boxplot pentru analiza categorica

Grafic 1: Distributia Variabilei Tinta

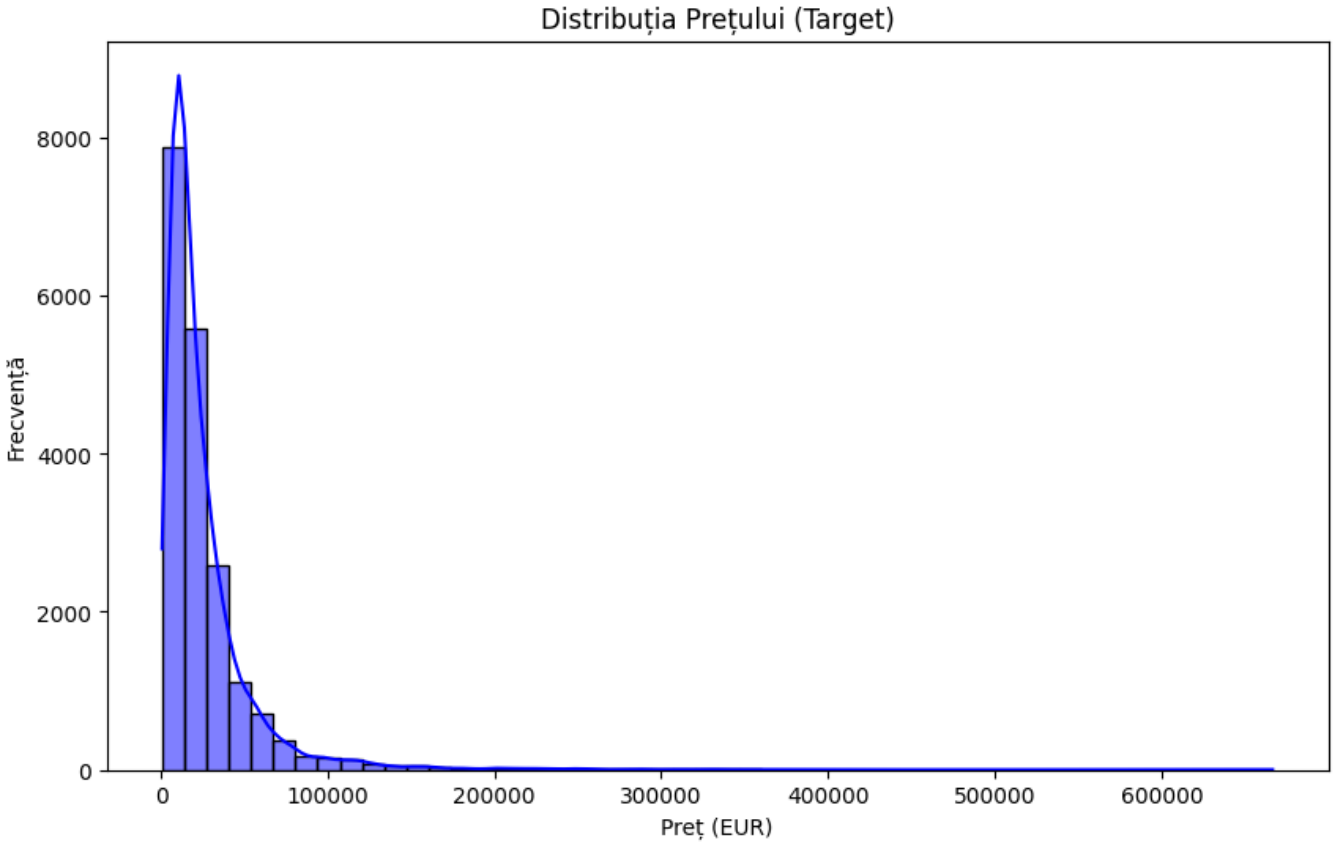

Din acest grafic intelegem natura problemei de regresie. Asimetria puternica sugereaza ca **logaritmarea variabilei tintă** (cu `np.log1p`) inainte de antrenare este o tehnica standard pentru a imbunatati performanta modelului, in special pentru a reduce impactul outlierilor si a normaliza distributia.

Grafic 2: Analiza datelor lipsa

Setul de date contine multe date lipsa asa ca acest grafic ne ajuta sa vedem care sunt coloanele cu cele mai multe valori lipsa pentru a ne putea alege strategia pe mai departe.

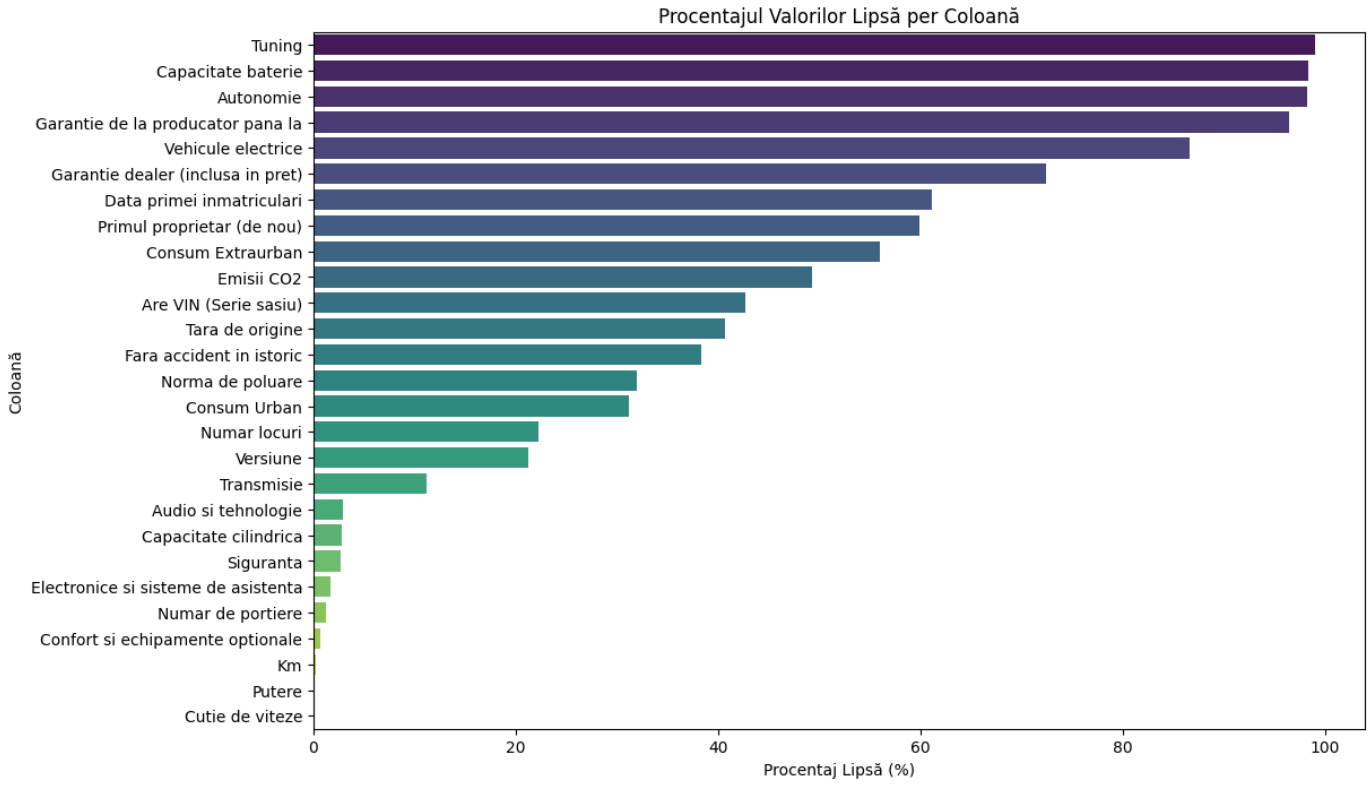

Identificarea procentului de date lipsa pe coloane ajuta la alegerea strategiilor adecvate de imputare/preprocesare. Coloane precum Tuning, Autonomie, și Capacitate baterie au un procent foarte mare de missing (peste 85%), indicand ca lipsa lor este adesea informativa. Acest lucru implica o preprocesare diferita a datelor nu doar imputarea lor.

Grafic 3: Matricea de corelatie

Am realizat acest grafic intre atributele numerice cheie si pret. Matricea de corelatie evidentiaz rapid Si vizual relaTiile liniare dintre atributele numerice Si variabila tinta, adica pret.

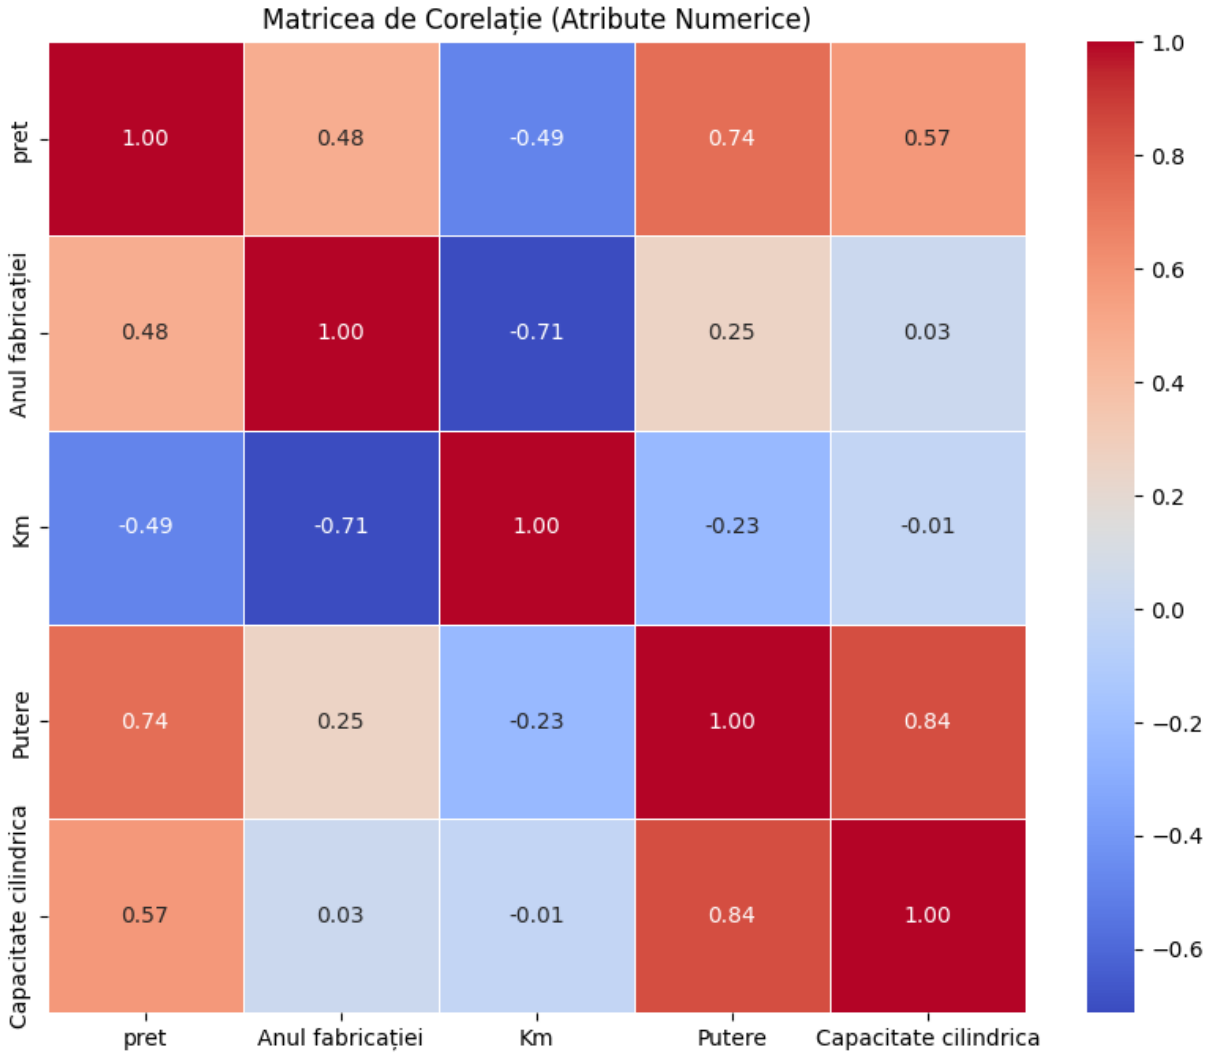

Corelația cu pret:

Se observa o corelație pozitiva puternica intre `Putere` si `pret` ($\rho \approx 0.76$) si o corelatie negativa puternica intre `Km` si `pret` ($\rho \approx -0.49$). Acest lucru inseamna, intuitiv, ca pretul unei masini creste cu cat este mai puternica si scade cu cat are mai multi kilometri.

Interpretare: Cele mai puternice corelatii cu pretul (target) sunt:

1. `Putere`: Cu cat masina este mai puternica, cu atat pretul creste.
2. `Km`: Cu cat masina are mai multi kilometri, cu atat pretul scade.
3. `Anul fabricației`: O masină mai noua (an mai mare) are un pret mai mare.

Grafic 4: Boxplot Analiza categorica

Am utlizat un grafic de tip boxplot pentru a vizualiza distributia preturilor pentru diferitele categorii de Combustibil. Boxplot-ul este excelent pentru a compara distributiile unei variabile numerice (pret, in cazul de fata) pe diferite categorii. Acest tip de grafic pune in evidenta mediana, dispersia si outlierii.

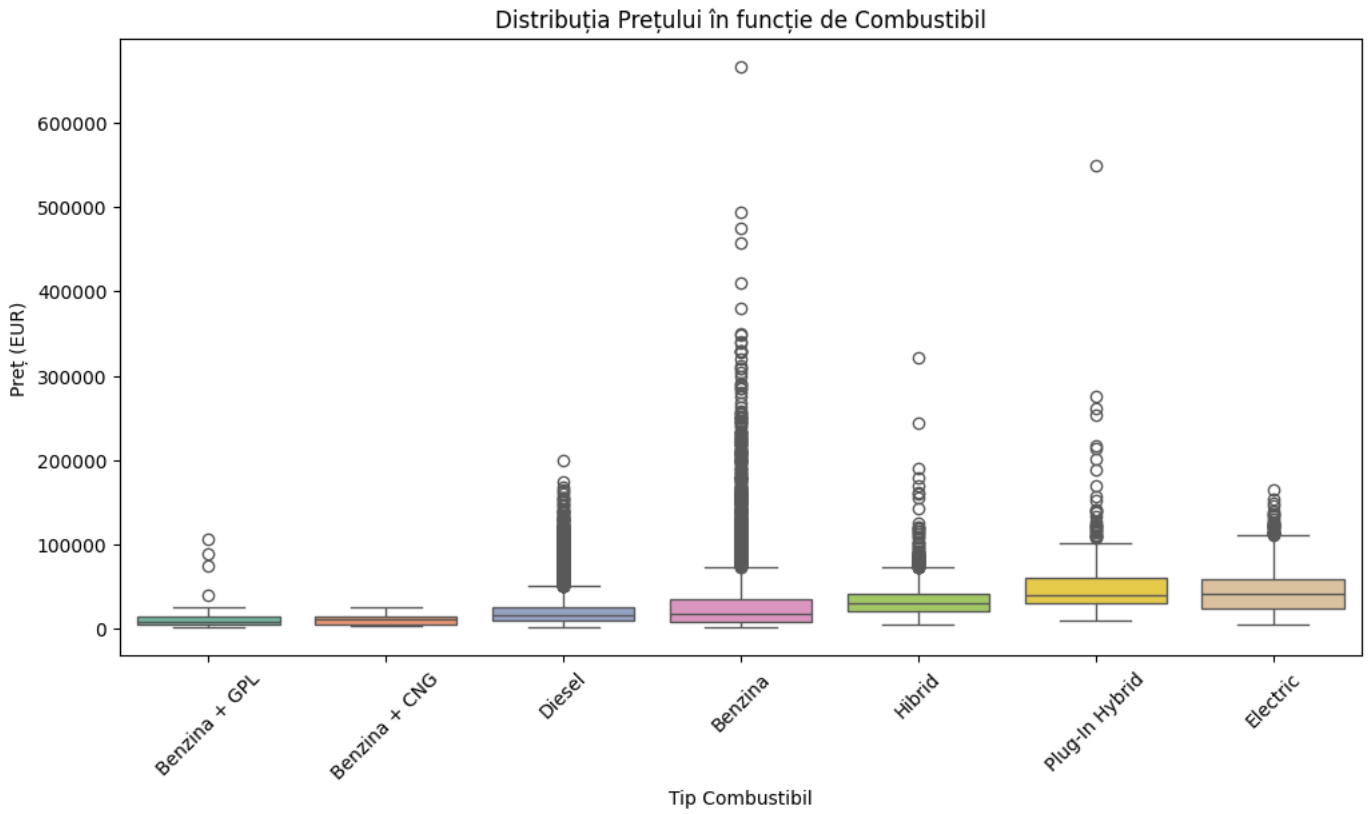

Din grafic se inteleg urmatoarele:

- Categoriile 'Electric' și 'Plug-In Hybrid' prezinta, in medie, cele mai mari preturi.
- Categoria 'Benzina' este cea mai diversa, avand atat cele mai mici, cat si unele dintre cele mai mari preturi (outlieri), indicand o dispersie mare (cea mai mare inegalitate de pret).
- Mediana pretului pentru 'Diesel' si 'Benzina' este semnificativ mai mica decat pentru celelalte categorii, dar prezinta, de asemenea, un numar mare de outlieri.

Preprocesarea datelor

Preprocesarea datelor a fost implementat prin funcTii custom Si un pipeline Scikit-Learn (ColumnTransformer) pentru a gestiona tipurile mixte de date si valorile lipsa.

Functii custom si feature engineering

Pentru coloanele cu unitati de masura am scris o functie auxiliara `extract_number(val)` pentru a extrage doar valoarea numerica a valorii din coloana. Acest lucru de aplica penrtu urmatoarele coloane: Putere, Capacitate Cilindrica, Garantie Dealer.

Coloanele Autonomie si Capacitate baterie au fost imputate cu zero, deoarece lipsa valorii este un indicator ca vehiculul nu este electric/hibrid.

Functia `process_special_cases` **creaza atribute binare** (Este_Electrica, Este_second_hand) prin binarizarea coloanelor initiale Primul proprietar, Fara accident, Are VIN, Garantie de la producator bazate pe prezenta/absenta valorii.

Functia `calculeaza_vechime` creaza coloana `vechime_ani` calculand cat timp a trecut de la prima inmatriculare pana in prezent. Asa cum se observa din analiza de corelatie, varsta vehiculului este un predictor cheie al pretului. Valorile lipsa din "Data primei inmatriculari" au fost imputate cu mediana pentru a reduce influenta outlierilor.

Coloanele de tip lista (Audio si tehnologie, Siguranta, Confort si echipamente optionale) le-am transformat in multiple coloane binare (0/1) bazate pe prezenta celor 15 cele mai frecvente dotari. Aceasta tehnică reduce cardinalitatea, tinand cont doar cele mai predictive dotari si previne explozia numarului de coloane.

Am eliminat coloanele cu peste 85% valori lipsa (Tuning, Autonomie) deoarece nu aduceau suficienta informatie. De asemenea, am folosit Matricea de Corelatie pentru a valida pastrarea atributelor 'Putere' si 'Anul fabricatiei', care au o corelttie puternica cu pretul.

Imputarea Standard

S-a folosit mediana pentru coloanele numerice ramase (ex: Km, Putere) si cea mai most_frequent pentru cele categorice. Mediana este robusta la outlieri, iar most_frequent este o metoda comuna pentru datele categorice. Am folosit clasa SimpleImputer din sklearn.

Discretizarea datelor

Nu am aplicat discretizarea atributelor numerice (ex: transformarea km in intervale) deoarece algoritmii bazaii pe arbori (Random Forest, Gradient Boosting) gestioneaza eficient datele continue prin split-uri interne, iar discretizarea ar fi dus la pierderea de informatie.

Logaritmarea tintei

S-a aplicat $\text{log}(1+x)$ (adica np.log1p) pe variabila tintA. Justificare: Conform GRAFICULUI 1, distribuția pretului este puternic asimetrica, iar logaritmarea ajuta modelul de regresie sa minimizeze eroarea relativa si s imbunatateasca performanta.

Pipeline

Am folosit `StandardScaler()` pentru a aduce atributele la aceeasi scara (media 0 si deviatia 1), prevenind astfel ca atributele cu valori foarte mari sa domine nejustificat modelele. Acest lucru se aplica pe atributele numerice finale.

Am folosit `TargetEncoder()` pe atributele categorice cu cardinalitate mare (vezi cell 32). Aceasta metoda este eficienta pentru atributele cu foarte multe valori unice pentru ca previne explozia numarului de coloane. Functioneaza prin a inlocui fiecare categorie cu **media variabilei tinta** (care pentru noi e logaritmata)pentru acea categorie.

Am folosit `OneHotEncoder()` pe atributele categorice cu cardinalitate mica. Potrivit pentru un numar mic de categorii, mentinand informatia fara a crea o problema de "curse of dimensionality".

In final am dat drop coloanelor de care nu mai e nevoie, adica nume, data primei inmatriculari (pentru ca am transformat-o in coloana vechime_ani) si coloanei target (pret).

Modele antrenate

S-au antrenat si evaluat trei tipuri de modele de regresie, inclusiv doua configuratii pentru Gradient Boosting (cu quantile si fara), urmarind metricile MAE (Mean Absolute Error), MSE (Mean Squared Error), RMSE (Root Mean Squared Error) și R^2 Score pe setul de validare.

Toate modelele au folosit Target-ul logaritmat (y_train, y_val) pentru antrenare, iar prediciile le-am transformat inapoi in Euro (cu `np.expm1(y_pred)`) inainte de calculul metricilor.

Pentru optimizarea hiper-parametrilor am folosit Randomized Search with Cross-Validation (cv=3) pe setul de antrenare.

Nu am inclus **Logistic Regression** pentru ca targetul pe acest set de date nu este unul categoric.

Random Forrest

Parametri optimi:

- n_estimators: 300,
- min_samples_leaf: 2,
- max_features: 1.0,
- max_depth: 30

Acesti parametri au fost gasiti cu Randomized Search with Cross-Validation.

Metrici

	Model	MAE	MSE	RMSE	R2
0	Random Forest Regressor	3998.480035	8.426518e+07	9179.606895	0.901869

MAE este de aproximativ 4000 EUR, ceea ce reprezintă o eroare relativ mare avand in vedere concentrarea preturilor. Scorul R^2 este de 0.90 si indica o potrivire buna a modelului la variabilitatea datelor.

Gradient Boosting Regressor

Parametri Optiomi:

- subsample: 1.0,
- n_estimators: 500,

- max_depth: 7,
- learning_rate: 0.05

Metrci

	Model	MAE	MSE	RMSE	R2
0	Gradient Boosting Regressor	3390.323713	6.127896e+07	7828.087972	0.928638

Acest model a obtinut cele mai bune performante, cu cel mai mic MAE (~3390 EUR) si cel mai mare R^2 (0.9286). Aceasta confirma ca, pe datele preprocesate si logaritmice, Gradient Boosting este cel mai potrivit algoritm.

Gradient Boosting Regressor cu Quantile

Parametrii optimi sunt la fel ca la modelul fara quantile.

	Model	MAE	MSE	RMSE	R2
0	GBR (Quantile - Median)	4707.295597	1.190825e+08	10912.492416	0.861322

Analiza erorilor si a intervalului de predictie:

Desi are un R^2 mai mic, scopul acestui model este de a oferi intervale de predictie, nu neaparat cea mai buna predictie punctuala.

S-au antrenat trei cuantile:

- $\alpha=0.05$ (Limita inferioara)
- $\alpha=0.50$ (Mediana)
- $\alpha=0.95$ (Limita superioara)

Predictiile $\alpha=0.05$ și $\alpha=0.95$ definesc un interval de $\mathbf{\sim 90%}$ de predictie. De exemplu, pentru prima observatie, modelul prezice ca pretul real (69008 EUR) se va afla in intervalul $\mathbf{[50113, 67700]}$ EUR, indicand o subestimare.

	Preț Real (EUR)	Cuantila 0.05 (Low)	Cuantila 0.50 (Median)	Cuantila 0.95 (High)
0	69008.0	50113.095708	64338.673298	67700.692823
1	7750.0	6491.612844	7748.612750	9582.151991
2	7999.0	11278.455570	15378.344524	15975.989983
3	8650.0	8689.839845	14176.366696	13805.238177
4	18949.0	18001.397871	18134.480052	29439.569965

Support Vector Regressor (SVR)

Parametri Optimi:

- C: 1
- kernel: 'rbf'
- gamma: 'scale'

	Model	MAE	MSE	RMSE	R2
0	Support Vector Regressor	3920.392724	1.148508e+08	10716.845606	0.866251

Metrici:

- MAE: ~3900 EUR
- R2 Score: ~0.87

Observație: SVR a necesitat scalarea datelor (StandardScaler) pentru a funcționa corect, dar a fost mai lent la antrenare decât modelele bazate pe arbori.

Quantile Regressor (Liniar)

Am testat si modelul liniar `QuantileRegressor` ca baseline. in cod acesta este comentat deoarece rularea pe laptop-ul meu dureaza foarte mult, dar am inclus aici metricile imprtante.

Metrici (Mediana):

- MAE: ~4800 EUR
- R2 Score: ~0.82

Concluzie: Performanța mai slabă comparativ cu GBR confirmă că relația dintre atribute și preț nu este strict liniară.

Tabel Centralizator (Cross-Validation)

Pentru o evaluare robust, am rulat o validare Incrucisata (5-fold) pe setul de antrenare. Iata media si deviasia standard a metricilor:

Model & Hiperparametri	R2 (Mean ± Std)	MAE (Mean ± Std)	RMSE (Mean)
Random Forest \n300 est, 30 depth	0.959 ± 0.002	0.115 ± 0.005	0.176
Gradient Boosting \n500 est, 0.05 lr	0.965 ± 0.003	0.109 ± 0.005	0.163
SVR \nrbf, C=1	0.940 ± 0.003	0.147 ± 0.006	0.214
GBR Quantile (Median) \nalpha=0.5	0.962 ± 0.002	0.115 ± 0.005	0.17

Concluzii Finale

1. **Performanță:** Gradient Boosting este clar castigatorul, oferind cel mai bun compromis intre bias si varianta.
2. **Feature Importance:** Analiza importanței atributelor a confirmat corelațiile inițiale: `Putere`, `Vechime_ani` și `Capacitate cilindrica` sunt cei mai puternici predictori.
3. **Incertitudine:** Folosirea regresiei pe cuantile ne oferă un interval de siguranta util in practica, desi am observat o tendinta de subestimare pentru vehiculele de lux (preț > 60k EUR).

Cele mai bune feature-uri

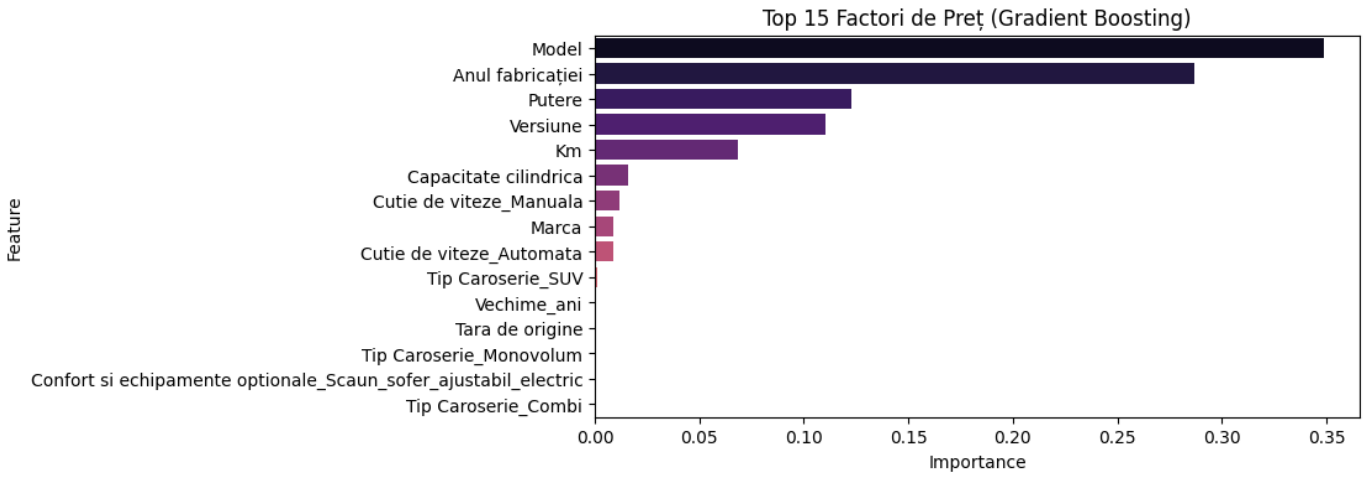

Setul de date Inchiriere de Biciclete

1. Vizualizarea datelor

Am realizat o serie de vizualizări pentru a intelege natura temporala a datelor si relatiile dintre atributele meteorologice si numarul de inchirieri:

- Distributia Variabilei tintă (`total`)
- Analiza Seriilor de Timp (Trend și Sezonalitate)

- Matricea de corelate intre atribute numerice
- Boxplot-uri pentru analiza orei si a conditiilor meteo

Grafic 1: Distributia Variabilei tintă

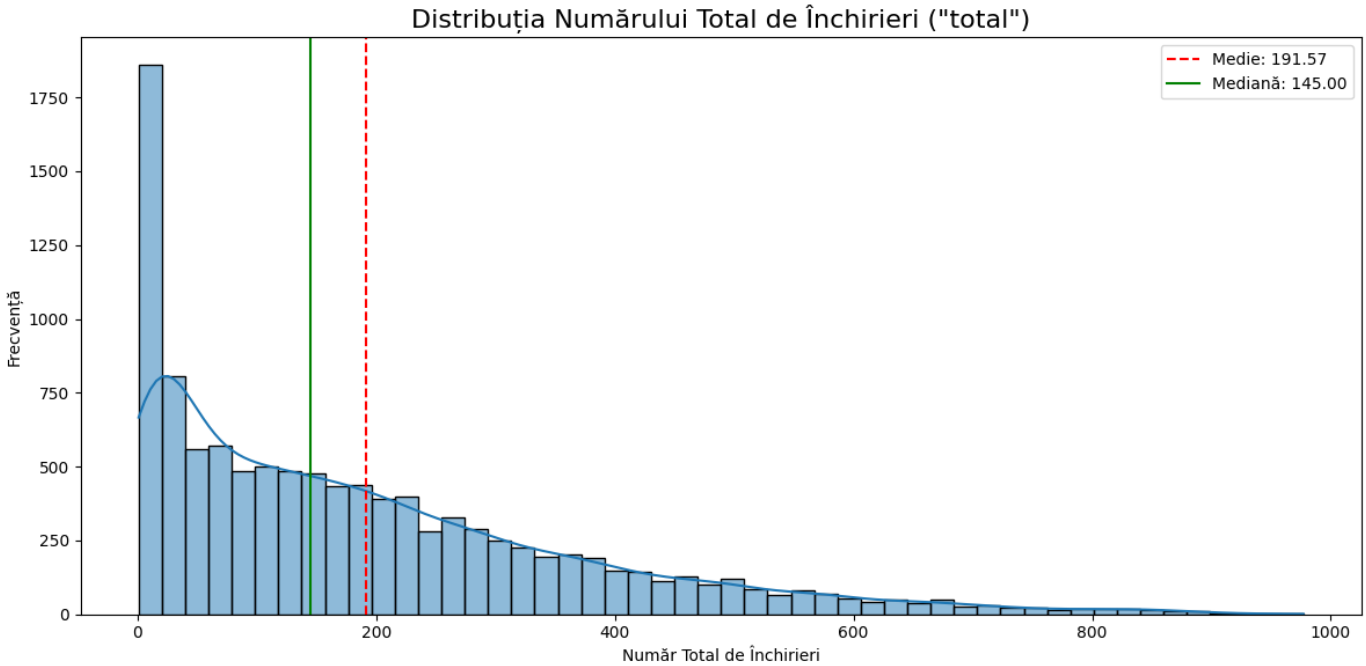

Analiza distributiei arată o asimetrie pozitivă (coadă lungă la dreapta). Desi am testat transformarea logaritmică (`np.log1p`), pentru modelele finale bazate pe arbori (Gradient Boosting), am utilizat tinta în formatul original sau cu functii de pierdere specifice (Quantile), care sunt robuste la outlieri.

Distributia logaritmata arata asa:

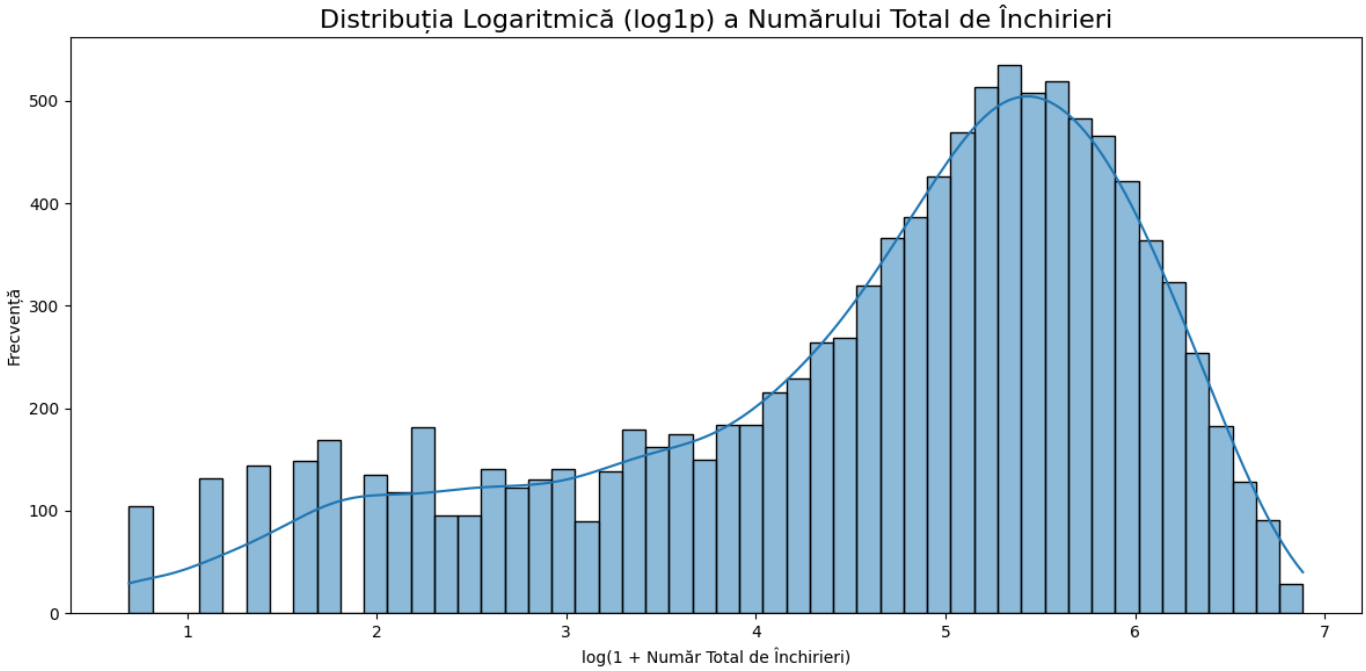

Grafic 2: Analiza Seriilor de Timp (Agregare Zilnică)

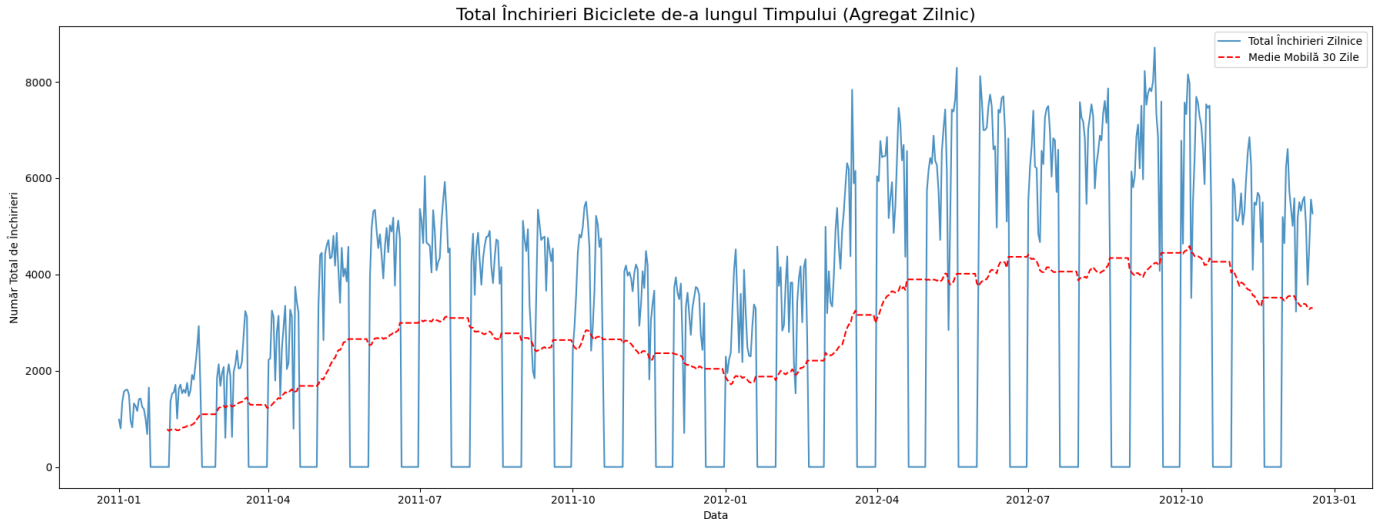

Interpretare: Graficul evidențiaza două componente majore:

1. **Sezonalitatea anuală**: Varfuri clare în lunile de vară/toamnă si scaderi masive iarna.
2. **Trendul crescător**: Volumul inchirierilor in al doilea an este vizibil mai mare decat in primul an, indicand o crestere a popularitatii serviciului.

Grafic 3: Matricea de corelație

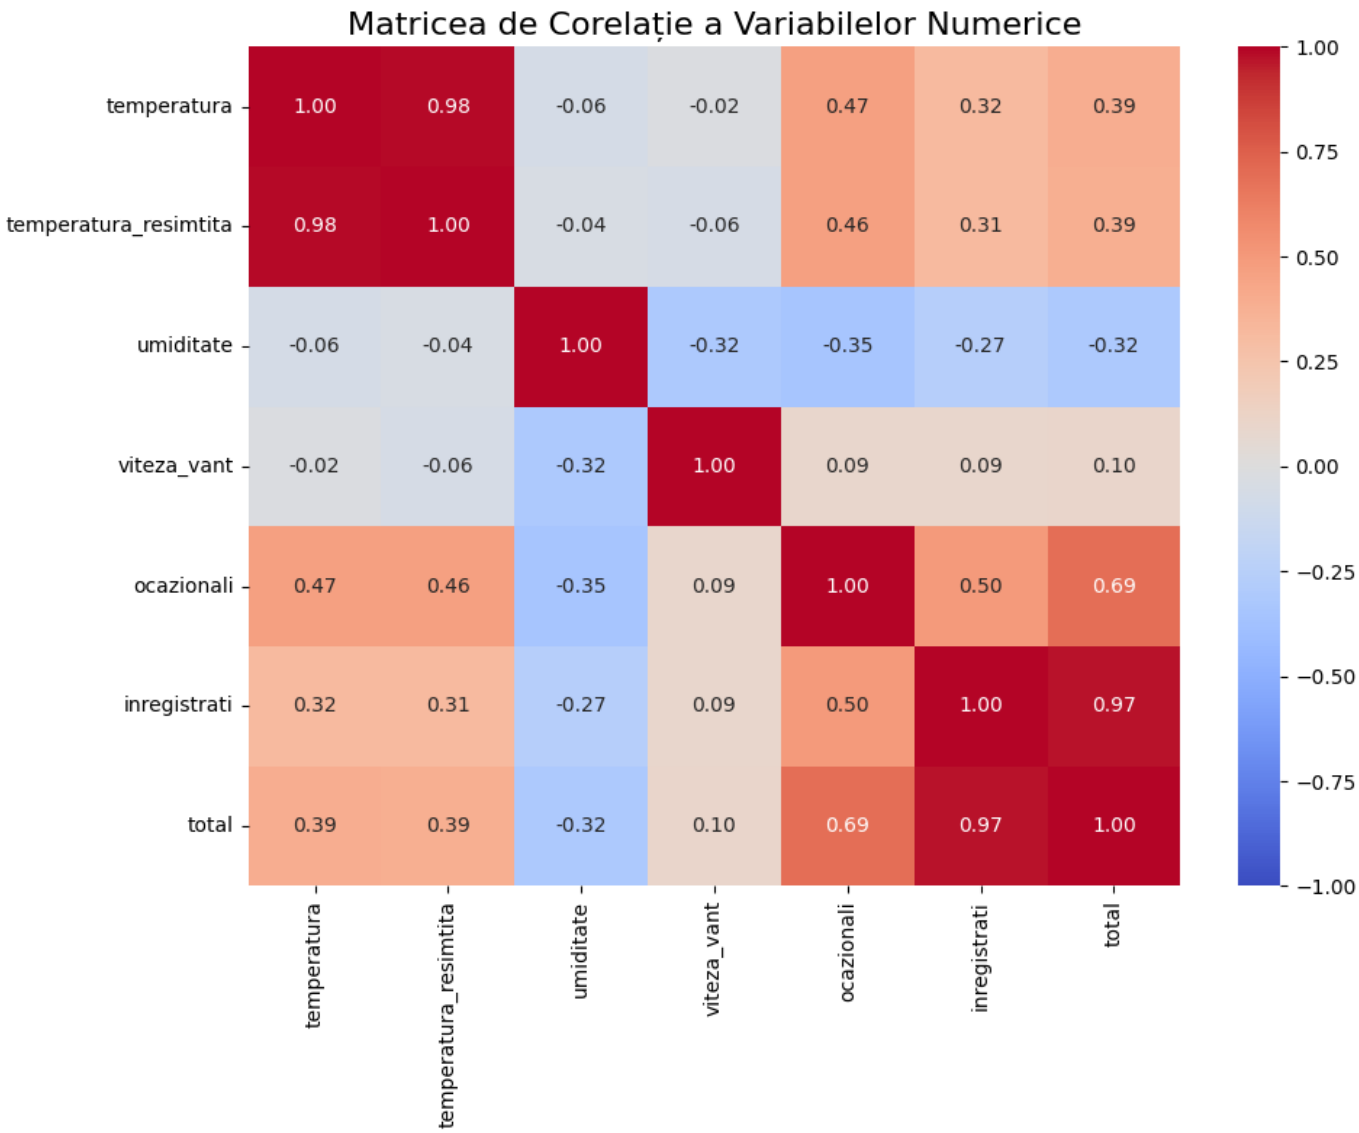

Corelația cu `total`:

- `temperatura`: Corelatie pozitiva. Temperaturile ridicate favorizează inchirierile.
- `umiditate`: Corelatie negativa. Umiditatea ridicata (asociată adesea cu ploaia) scade numarul de inchirieri.

Din cauza ca temperatura_resimtita are o corelatie foarte mare cu temperatura am decis sa exclud coloana temperatura_resimtita. Aceasta nu ar fi facut decat sa includa date ne-esentiale in setul de date pentru antrenament.

Grafic 4: Analiza Orelor (Boxplot)

Acesta este probabil cel mai informativ grafic pentru acest set de date.

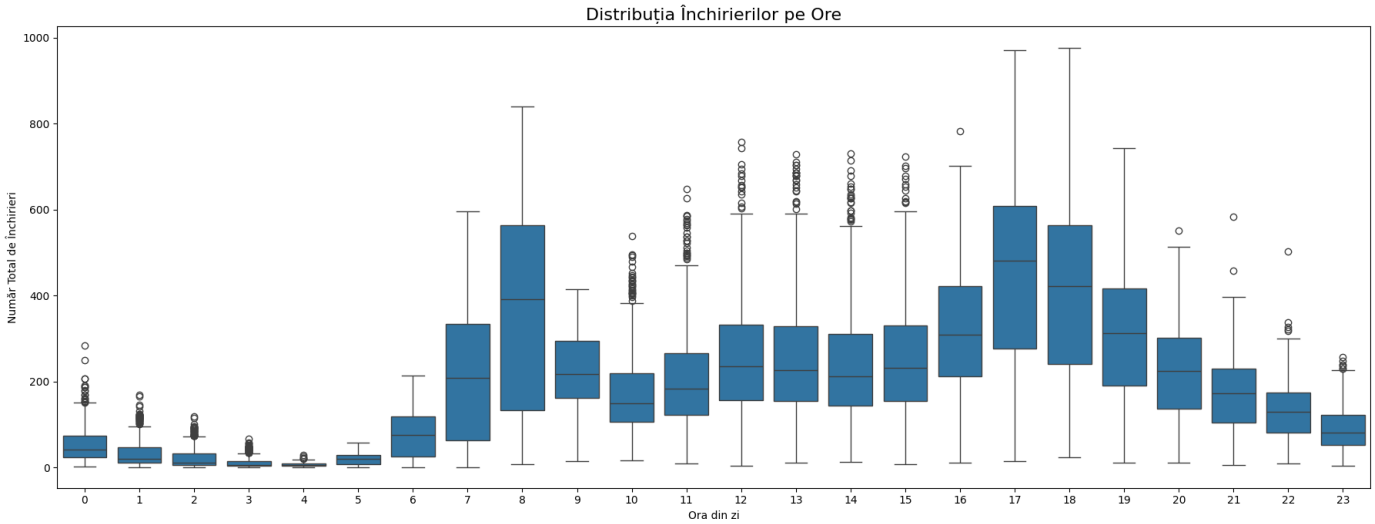

Interpretare:

- Se observa un tipar bimodal distinct: un varf dimineața (~08:00) si unul după-amiaza (~17:00 - 18:00).
- Aceasta indică faptul că bicicletele sunt folosite preponderent pentru **naveta** in zilele lucratoare.

Grafic 5: Boxplot-uri pentru atribute categorice

Acest set de 4 boxplot-uri ne permite sa analizăm cum influentează factorii externi (sezonul, vremea) si tipul zilei distributia numarului de biciclete inchiriate, adica total-ul.

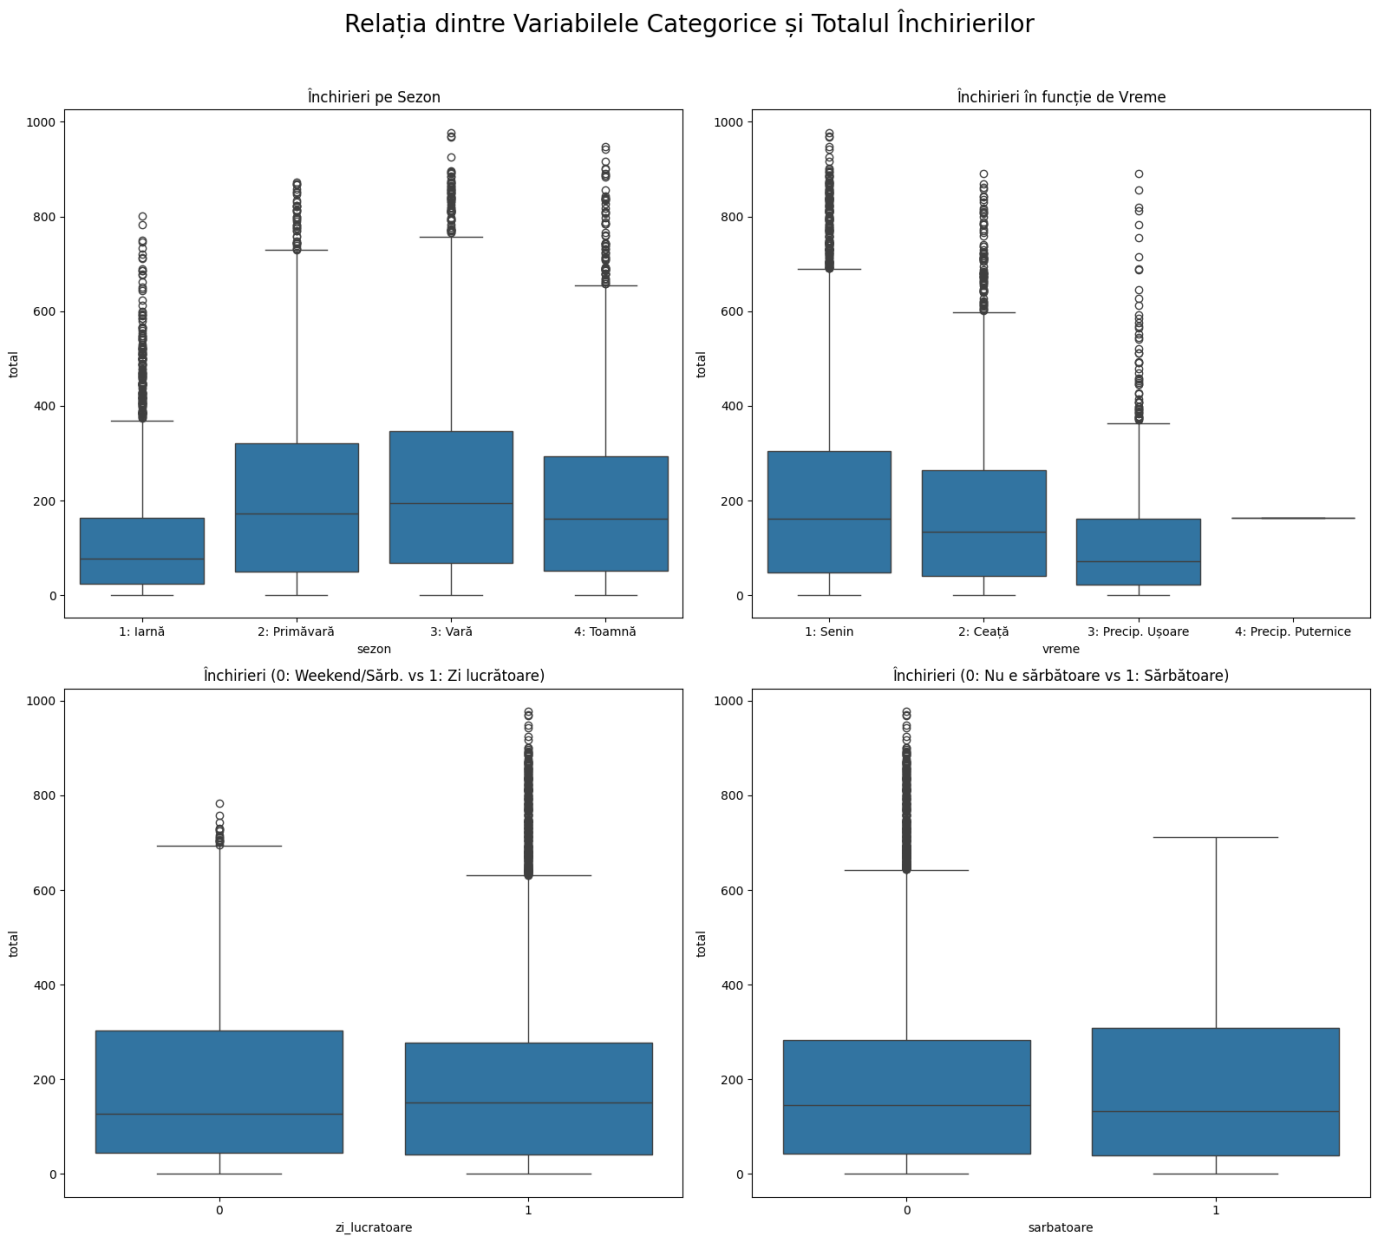

Interpretare

1. **Influenta Sezonului:**
   - Există o **sezonalitate puternica**. Așa cum era de așteptat, **Iarna (1)** inregistreaza cel mai mic număr de inchirieri (mediana cea mai joasă).
   - Varful activitatii este atins in sezoanele calde, **Vara (3)** avand cea mai ridicata mediana.
2. **Vremea:**
   - Vremea este un factor determinant. **Vremea 1 (Senin/Putini nori)** este cea mai favorabila, avand cea mai mare distributie si cei mai multi outlieri pozitivi.
   - Pe masura ce conditiile nu mai sunt atat de favorabile, numrul inchirierilor scade drastic.
   - **Vremea 4** are extrem de putine inregistrari, ceea ce confirma că serviciul este aproape neutilizat in conditii meteo severe.
3. **Zile Lucrătoare vs. Weekend:**
   - Mediana inchirierilor este usor mai ridicata in **zilele lucratoare** comparativ cu zilele libere (0).
   - prezenta multor outlieri in partea superioara pentru zilele lucratoare sugereaza momente de cerere extrema, fapt corelat cu graficul anterior al orelor care indica utilizarea pentru naveta.
4. **Sarbatori:**
   - Distributia pentru zilele care nu sunt sarbatori este similara cu cea a sarbatorilor (1), deși sarbatorile au o mediana usor mai scazuta si o varianta mai mica (mai puține valori extreme), probabil din cauza lipsei navetistilor.

2. Preprocesarea datelor

Preprocesarea a implicat `Feature Engineering` specific pentru serii de timp si utilizarea unui `ColumnTransformer`.

Feature Engineering (Ingineria Atributelor)

1. **Descompunerea Datei**: Din coloana `data_ora`, am extras `ora`, `luna` și `zi_saptamana`.
2. **Codare Ciclică (Cyclical Encoding)**: Deoarece ora 23:00 este apropiată de ora 00:00, dar numeric sunt indepartate, am transformat atributele temporale (`ora`, `luna`, `zi_saptamana`) in coordonate Sinus si Cosinus:
   - `hour_sin = sin(2 * pi * ora / 24)`
   - `hour_cos = cos(2 * pi * ora / 24)`
   - *Această tehnică ajută modelele să inteleaga continuitatea timpului.*
3. **Eliminarea coloanelor (Drop)**: Am eliminat `ocazionali` si `inregistrati` deoarece suma lor constituie variabila tinta, astfel am evitat un caz de data leakage. Oricum, aceste informatii nu sunt disponibile la momentul predictiei. De asemenea, am eliminat `temperatura_resimtita` din cauza corelatiei puternice cu `temperatura`.

Pipeline de Transformare

- **StandardScaler**: Aplicat pe atributele numerice (inclusiv cele ciclice) pentru a normaliza scara valorilor. Avem nevoie de date la aceeasi scara (media 0 si deviatia 1).
- **OneHotEncoder**: Aplicat pe variabilele categorice nominale: `sezon`, `vreme`, `zi_lucratoare`.

3. Modele Antrenate

S-au antrenat modele de regresie liniara, SVM si ansambluri de arbori (Random Forest, Gradient Boosting), folosind `RandomizedSearchCV` (cv=3) pentru optimizarea hiperparametrilor.

Linear Regression (Baseline)

- **MAE**: ~96
- **R2 Score**: 0.45
- *Concluzie*: Performanta slaba indica faptul ca relatiile dintre atribute (in special ora non-liniară) nu pot fi capturate de un model liniar simplu.

Random Forest Regressor

Parametri Optimi:

- `n_estimators`: 100
- `max_depth`: 20

tabel 1

- **MAE**: ~45.4
- **R2 Score**: 0.85
- Modelul a reusit sa captureze foarte bine interactiunile non-liniare dintre ora si conditiile meteo, insa nu este destul de performant.

Gradient Boosting Regressor (Cuantile)

Aceasta a fost abordarea principala a studiului. Am antrenat trei modele pentru a prezice distributia conditionata:

1. **Low ($\alpha=0.05$)**: Limita inferioara a intervalului de predictie.
2. **Median ($\alpha=0.50$)**: Predictia centrala (robusta la outlieri).
3. **High ($\alpha=0.95$)**: Limita superioara.

Rezultate pentru Mediana ($\alpha=0.50$):

- **MAE**: ~43.12 (Cel mai bun rezultat)
- **R2 Score**: 0.86

Analiza Intervalului de Predicție: Utilizand cele trei modele, am putut construi un interval de încredere de 90%. Graficul de mai jos (generat in notebook) arată cum predictia mediana urmareste datele reale, iar intervalul albastru acopera incertitudinea.

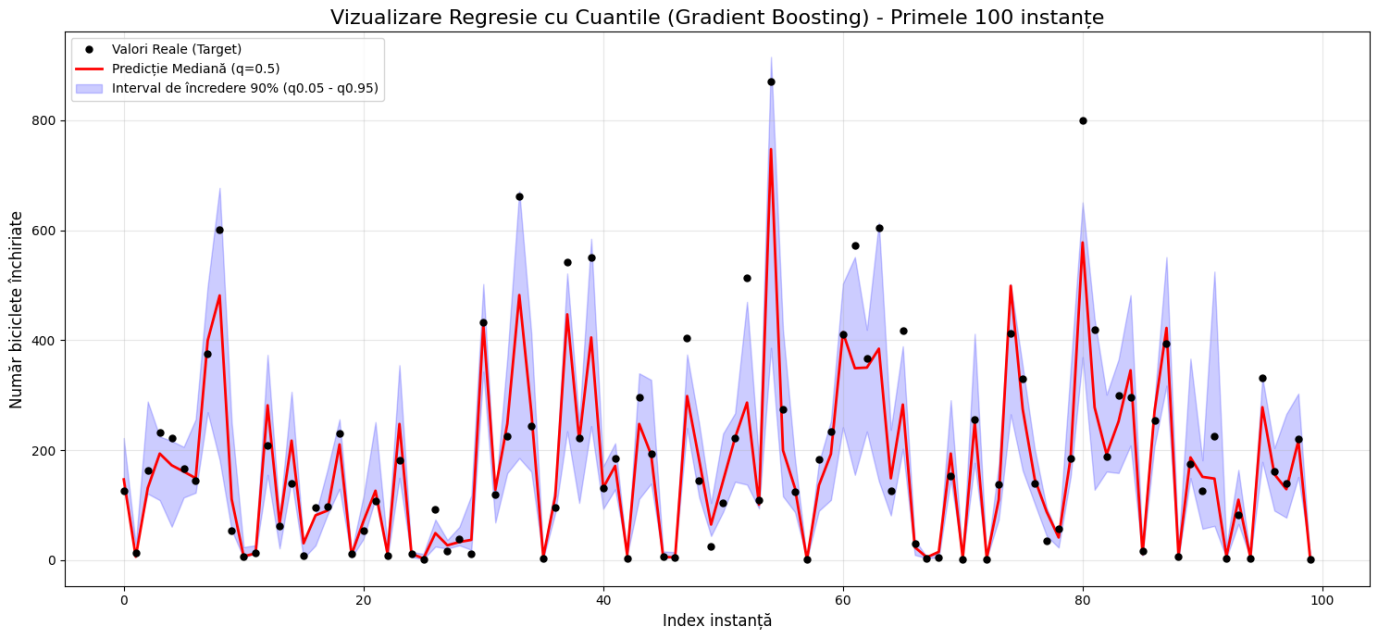

4. Tabel Centralizator (Cross-Validation)

Rezultatele finale, obținute prin validare încrucișată pe setul de antrenare:

Algoritm	MSE (Mean)	MAE (Mean)	R2 Score (Mean)
Linear Regression	18098.37	96.07	0.45
SVR	9812.56	59.34	0.70
Random Forest	4783.34	45.42	0.85
GBR (Squared Error)	4576.36	46.58	0.86
GBR Quantile (Median)	**4611.11**	**43.12**	**0.86**

5. Concluzii Finale

1. **Performanta:** Modelul **Gradient Boosting cu loss Quantile (Mediana)** a oferit cea mai buna acuratete (MAE minim). Modelele bazate pe arbori sunt net superioare celor liniare pentru acest tip de date.
2. **Importanța Atributelor:** Transformarea ciclica a orei si a lunii a fost esentiala. Ora din zi este cel mai puternic predictor.

Tabel final cu metrici

Algoritm	Hiper-parametri	MSE (Mean)	MSE (Var)	MAE (Mean)	MAE (Var)	R2 (Mean)	R2 (Var)
SVR	{'C': 100, 'kernel': 'rbf'}	9812.56	58478.8	59.3443	0.951831	0.700439	1.99917e-05
RandomForestRegressor	{'max_depth': 20, 'n_estimators': 100}	4783.34	4203.8	45.4271	0.101005	0.853951	1.97884e-06
GradientBoostingRegressor_SquaredError	{'alpha': 0.9, 'learning_rate': 0.1, 'loss': 'squared_error', 'max_depth': 5, 'n_estimators': 100}	4576.36	2925.8	46.586	0.152837	0.86027	9.96532e-07
LinearRegression	{}	18098.4	75420.3	96.0734	1.60414	0.447352	0.000101288

Algoritm	Hiper-parametri	MSE (Mean)	MSE (Var)	MAE (Mean)	MAE (Var)	R2 (Mean)	R2 (Var)
GBR Quantile (Median)	{'alpha': 0.5, 'learning_rate': 0.1, 'loss': 'quantile', 'max_depth': 10, 'n_estimators': 200}	4611.11	16801.4	43.1289	0.110928	0.859237	5.94055e-06
Quantile Regressor (Median)	{'alpha': 0.01, 'solver': 'highs'}	20183.5	84544	91.0503	0.901417	0.383728	6.1319e-05
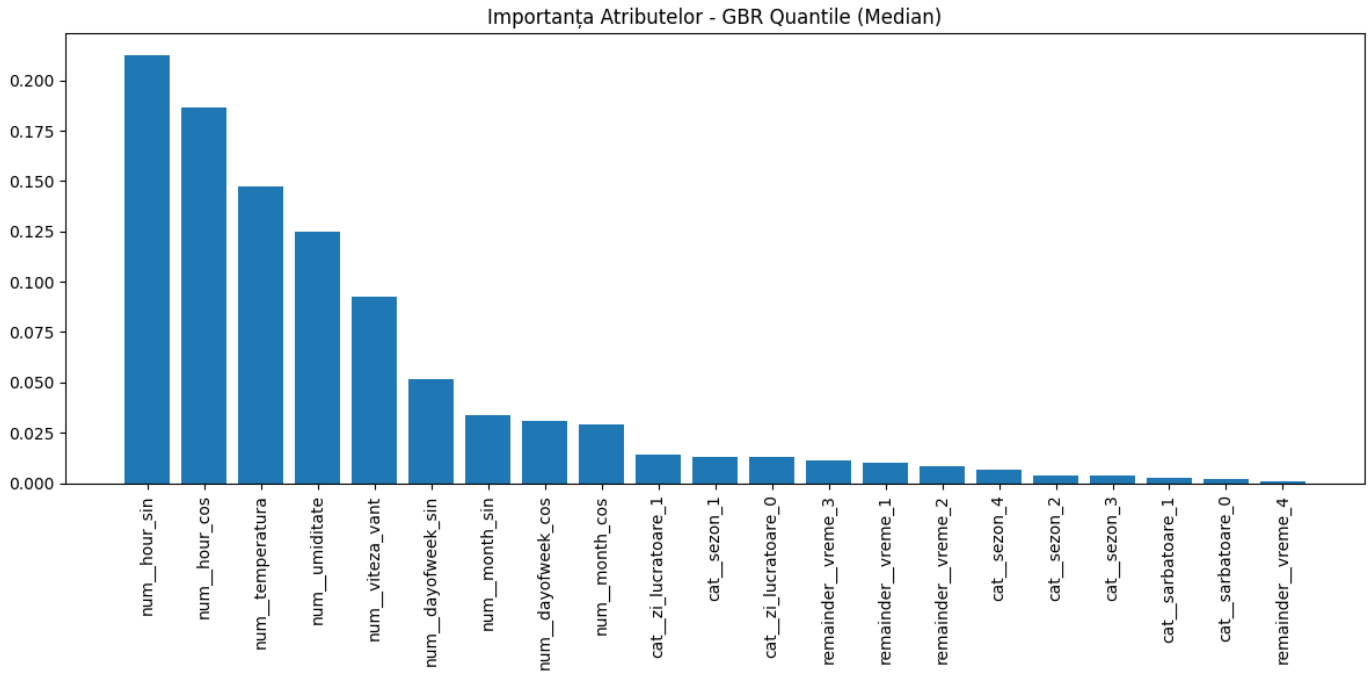
Cele mai bune feature-uri